Introdução ao Aprendizado de Máquina

Profª. Samira Santos da Silva

Universidade de Itaúna

19 de Outubro de 2018

Sumário

Sumário

O que é Aprendizagem de Máquina?

Aprendizagem de Máquina ou Machine Learning (ML)

- Área da **Inteligência Artificial** onde desenvolve-se algoritmos para ensinar uma máquina a desempenhar determinadas tarefas.
- Um algoritmo de ML recebe um **conjunto de dados de entrada** e, baseado nos padrões encontrados, **gera saídas**.
- Cada entrada possui suas *features*.
  - Extrair as features dos dados é o **ponto inicial** para um algoritmo de ML.

História

História

- O termo **"machine learning"** foi criado por **Arthur Samuel**, engenheiro do MIT, em 1959.
- Ele descrevia este conceito como "um campo de estudo que dá aos computadores **a habilidade de aprender** sem terem sido programados para tal".
- Samuel trabalhava em um projeto para criar uma **máquina autônoma** com estas características.

História

História

Figura: Arthur Samuel e um IBM 700 na década de 1950.

História

História

- Mas foi somente com o advento da **Internet** que ML começou a tornar forma.
- Com **tanta informação** coletada e armazenada na Web, foi necessário **meios de organizar** esse conteúdo gigantesco de forma **automatizada**.

Aplicações

- Existem **diversas aplicações** para Machine Learning.
- Alguns exemplos: Reconhecimento de Padrões, Recomendação, Mineração de Texto, Análise de Sentimentos, etc.

Aplicações

Reconhecimento de Padrões

- **Atribuir** uma **classe** (padrão) a um conjunto de dados **desconhecidos**.
- Exemplos:
  - Reconhecimento de padrões em imagens.
  - Reconhecimento de padrões em textos.
  - Reconhecimento de padrões em áudios.

Aplicações

Reconhecimento de Padrões

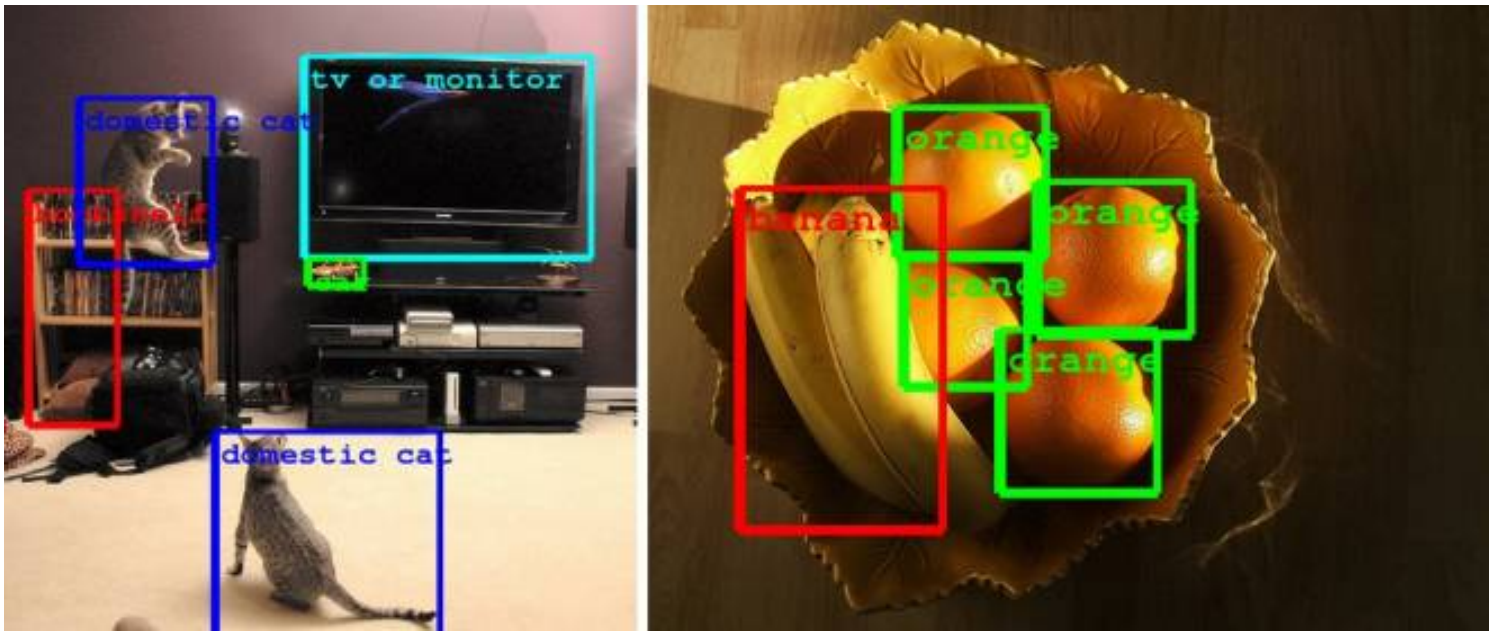

Aplicações

Recomendação

- Um **sistema de recomendação** combina técnicas computacionais para **selecionar itens personalizados** com base nos **interesses** dos usuários e conforme o **contexto** no qual estão inseridos.
- Ex. de itens: livros, filmes, notícias, música, vídeos, anúncios, links patrocinados, produtos de uma loja virtual, etc.
- Recomendações são exibidas de acordo com um "**score**" (nota).

Aplicações

Recomendação

Aplicações

Mineração de Textos

- Explorar **grandes quantidades de dados** à procura de **padrões consistentes** para detectar **relacionamentos sistemáticos entre variáveis** gerando informação.
- Ex: Supermercado pode minerar seus dados de compras e acabar percebendo que quem compra cerveja geralmente compra fraldas.
  - Então por que não colocar cervejas e fraldas próximos?

Aplicações

Mineração de Textos

Aplicações

Análise de Sentimentos

- Processo para conseguir **identificar sentimentos** embutidos em **textos** (geralmente de mídias sociais).
  - É positivo?
  - É negativo?

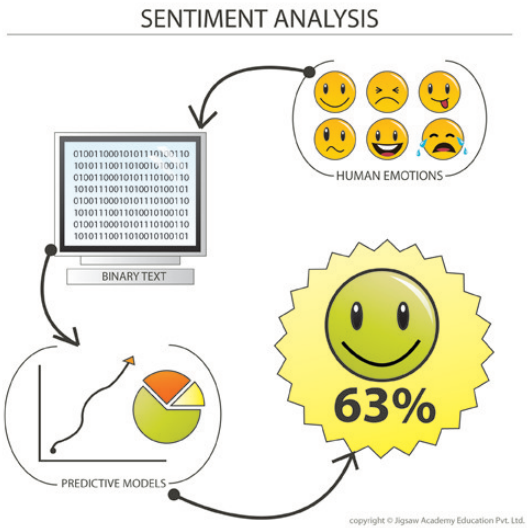

Exemplos Práticos de Aplicações

1 - Indicar a qualidade de um vinho

Exemplos Práticos de Aplicações

2 - Escolher o melhor filme para o seu final de semana

Exemplos Práticos de Aplicações

3 - Tirar motoristas de grandes congestionamentos

Exemplos Práticos de Aplicações

4 - Reconhecimento de placas de carro em imagens

Exemplos Práticos de Aplicações

5 - Reconhecimento de Faces no Facebook

Exemplos Práticos de Aplicações

6 - Exibição de Postagens do seu Interesse

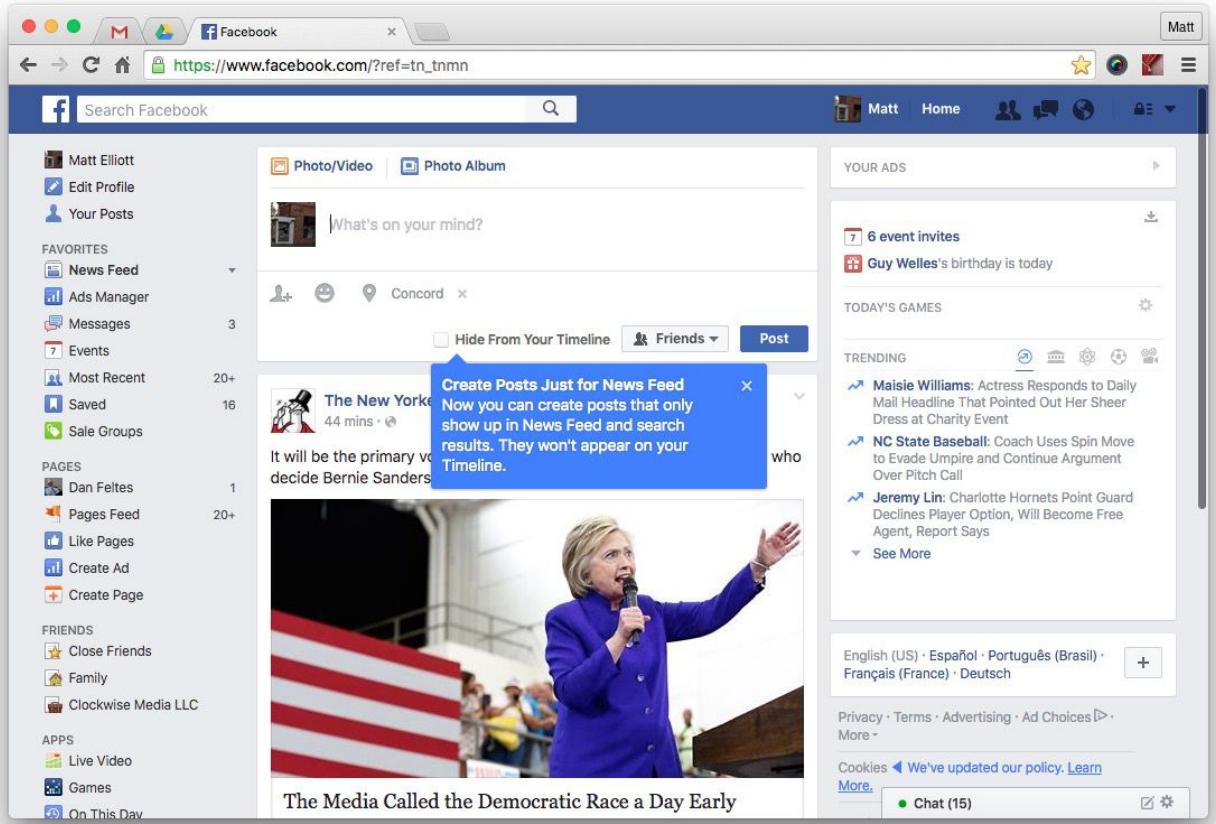

Exemplos Práticos de Aplicações

7 - Previsão de Derrame

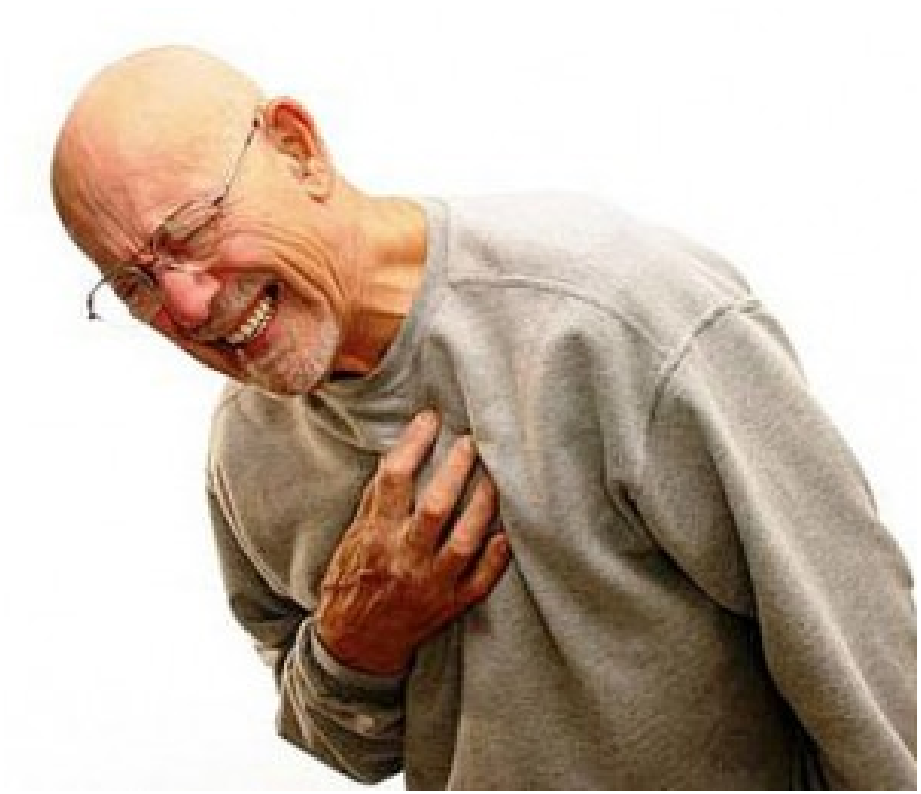

Exemplos Práticos de Aplicações

8 - Carros Autônomos

Sumário

O que é uma Feature?

Feature

- Feature é uma **característica** que descreve um objeto.
- Qualquer atributo de um objeto pode ser tratado como feature: um número, um texto, uma data, um booleano etc.

O que é uma Feature?

Feature

- No objeto Pessoa, vemos vários atributos que o descreve.
- Esses atributos são suas features:

O que é uma Feature?

Feature

- Na tabela abaixo, temos um conjunto maior de dados, onde:
  - Cada coluna é uma feature que descreve a linha;
  - Cada linha é uma entrada e tem seu conjunto de features.

Nome	Data de Nascimento			Peso	Altura	Sexo
	Dia	Mês	Ano			
Pessoa 1	05	02	1982	85	1,72	M
Pessoa 2	13	10	1990	60	1,50	F
Pessoa 3	05	01	1972	75	1,63	M

O que é uma Feature?

Feature

- As features são as **entradas** dos **algoritmos de ML**.
- Quanto **mais detalhes** o algoritmo tiver sobre uma entrada, mais **facilmente** achará **padrões** nos dados.
- Features **ruins** podem prejudicar o desempenho do algoritmo.
- Features **boas** são a chave para o sucesso de um algoritmo.

O que é uma Feature?

Feature

- Grande parte do trabalho em ML consiste em **trabalhar os dados** e **gerar boas features** em cima deles.
  - Engenharia de features ou feature engineering.
- Existem **diversas técnicas para gerar features**:
  - Conhecendo a natureza dos dados;
  - Aplicando matemática e estatística para criá-las em cima dos dados.

Sumário

Extração de Features

Extração de Features

- Tem o **objetivo** retirar de imagens, vídeos, textos ou aúdios informações que descrevem esses tipos de mídia.
- O **resultado** da extração de características é um **vetor de atributos** descrevendo cada objeto.
- Existem **métodos adequados** para cada tipo de **mídia**.

Extração de Features em Imagens

Extração de Features Imagens

- Na extração de features em imagens, por exemplo, existem **descritores especializados** em representar:
  - Cores dos Objetos;
  - Formas dos Objetos;
  - Textura dos Objetos;
  - Relacionamentos entre Objetos;
  - etc.

Extração de Features em Imagens

Descrição de Cor - Exemplo: Histograma

- Vetor $[h_1, ..., h_n]$ onde cada h_j contém a quantidade de pixels de cor j na imagem.
- Para comparação de histogramas utiliza-se:

$$D(H, H') = \frac{\sum_i min(h_i, h'_i)}{\sum_i h'_i}$$

Extração de Features em Imagens

Descrição de Forma - Exemplo: Algoritmo detector de bordas

- Curvaturas obtidas a partir do contorno, com redução de mudanças (ruídos) na curvatura.

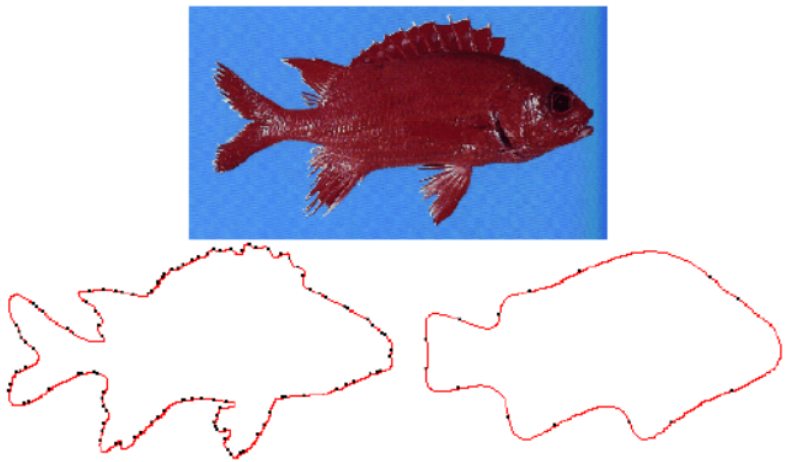

Extração de Features em Imagens

Descrição de Textura - Exemplo: Haralick Features

- Haralick propõe o uso de 14 medidas estatísticas como features.

Haralick *et al.*[19]
Contrast
Correlation
Difference entropy
Difference variance
Energy
Entropy
Homogeneity
Information measure of correlation 2
Information measure of correlation 1
Max correlation coefficient
Sum average
Sum entropy
Sum variance
Variance

Sumário

Aprendizagem

Aprendizagem Supervisionada x Não-supervisionada

- Tendo nossas **features em mãos** podemos aplicar **diversos algoritmos de aprendizado** nelas.
- Existem dois grandes grupos de algoritmos em ML: os de **aprendizagem supervisionada** e os de **aprendizagem não-supervisionada**.

Aprendizagem Supervisionada

Aprendizagem Supervisionada

- Tem-se um **conjunto de entradas A** que já **possuem as saídas**.
- Deseja-se **prever a saída** de um **conjunto de entrada B**.
- Se A é um **conjunto de tamanho considerável**, conhecer suas saídas permite com seja possível encontrar **padrões** que **relacionam entradas com saídas**.
- Assim, é possível **prever as saídas do conjunto B** com base nesses **padrões previamente encontrados**.

Aprendizagem Supervisionada

Aprendizagem Supervisionada

- Algoritmos que realizam este procedimento são denominados **supervisionados**.
- Algoritmos supervisionados são divididos em dois grupos: **classificação** e **regressão**.

Aprendizagem Supervisionada

Classificação

- É quando queremos prever uma **classificação**.
- As **classes** utilizadas no **aprendizado** devem ser as **mesmas** dos dados cujas classes são desconhecidas.

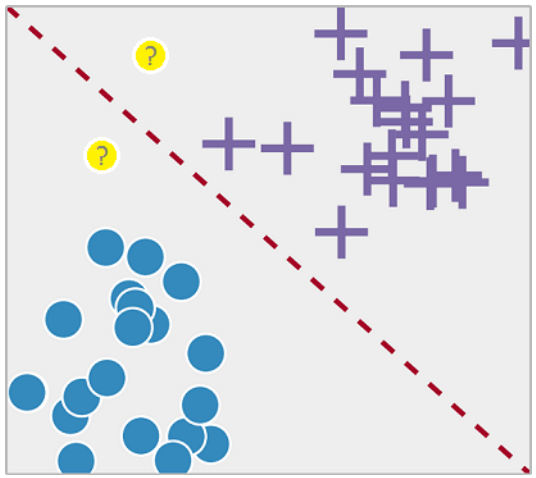

Aprendizagem Supervisionada

Classificação - Ex: classificar um e-mail como spam ou não spam.

- Coletou-se vários e-mails já **classificados** como **spam** ou **não spam**;
- **Treinou-se** um algoritmo que seria capaz de encontrar os **padrões** determinantes para **cada uma das classes**;
- Teria-se um **algoritmo** capaz de **ler um novo e-mail** e **classificar** como **spam** ou **não** baseado em suas características.

Aprendizagem Supervisionada

Regressão

- Quando queremos **prever um valor** e não uma classe.
- Os **dados** usados no **aprendizado** possuem também valores ao invés de classes.

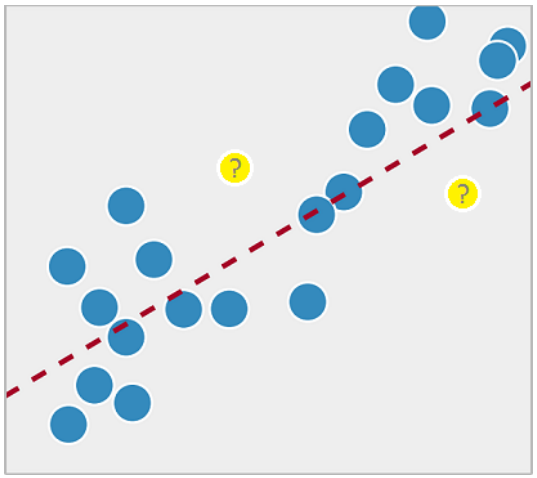

Aprendizagem Supervisionada

Regressão - Ex: determinar o preço de uma casa

- Coletou-se as features de **várias casas** e os seus **preços** (bolinhas azuis);
- Treinou-se um **algoritmo** capaz de criar uma **relação** entre as **features da casa** e o seu **preço**(linha vermelha);
- Logo, esse algoritmo é capaz de determinar o **preço de uma nova casa** (bolinhas amarelas) baseado em suas **características**.

Aprendizagem Supervisionada

Regressão

- No treinamento supervisionado, sempre utilizase **dados com saídas semelhantes** as que desejamos encontrar.
  - No exemplo 1: vários e-mails rotulados como **spam** e **não spam** foram usados no treinamento.
  - No exemplo 2: várias casas com seus **preços** foram usadas nos treinamento.

Aprendizagem Não-supervisionada

Aprendizagem Não-supervisionada

- Tem-se um conjunto de **entradas B sem as saídas** que deseja-se.
- Com base nas características desses dados, é possível gerar
  - Um agrupamento;
  - Processá-los a fim de gerar novas formas de expressar essas características.
- Algoritmos não-supervisionados podem ser divididos em dois grupos: **redução de dimensionalidade** e **clusterização**.

Aprendizagem Não-supervisionada

Redução de dimensionalidade

- Reduzir um conjunto de dados de **alta dimensão** para um **número menor de dimensões** de forma que **represente o máximo possível** os dados originais.
- A **dimensão** é a quantidade de features consideradas.
- Deve-se remover features que são **irrelevantes** ou **redundantes**.

Aprendizagem Não-supervisionada

Redução de dimensionalidade

- O objeto Pessoa contém 65 features, ou seja, **65 dimensões**.
- Após passar essas features pelo algoritmo, **reduzimos a 2 dimensões**.
- As novas features 1 e 2 representam o máximo possível as 65 features originais.

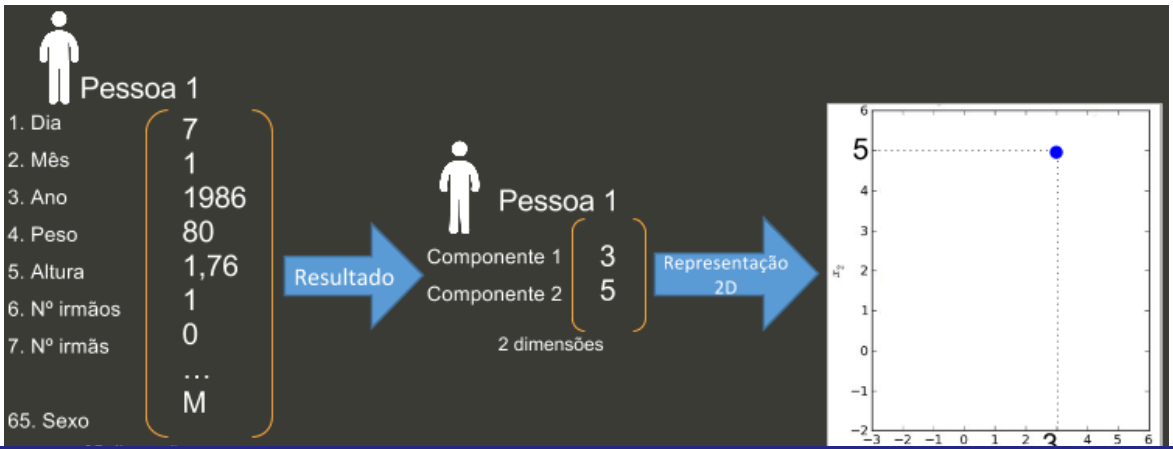

Aprendizagem Não-supervisionada

Redução de dimensionalidade

- É possível fazer a **mesma redução** pra **várias pessoas**.
- Com **2 features** é possível **enxergar melhor a distribuição dos dados**.
- Pessoas com **mesmas características** podem ficar mais **próximas** nesse tipo de representação. Enquanto pessoas muito **diferentes** ficam mais **distantes**.

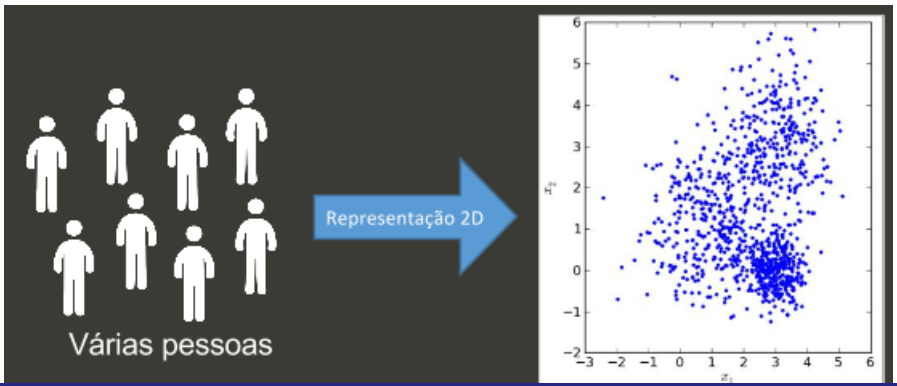

Aprendizagem Não-supervisionada

Redução de dimensionalidade

- Reduzimos para 2 dimensões para **melhor visualização**.
- Entretanto, algoritmos são capazes de lidar com **quantas dimensões forem necessárias**.
- Esse tipo de técnica pode ser usada para **facilitar a análise dos dados**, como no exemplo.

Aprendizagem Não-supervisionada

Redução de dimensionalidade

- Também utilizado quando features de alta dimensão impedem algoritmos de funcionarem corretamente.
- Isso ocorre, principalmente, se **número de features** > **número de entradas**.
  - Mal da dimensionalidade.
- Nesse caso, reduz-se features para um número mais aceitável e então faz-se o treinamento normalmente.

Aprendizagem Não-supervisionada

Clusterização

- **Agrupamento dos dados** baseado em suas características.
- Os grupos formados são chamados de **clusters**.
- Poderíamos querer agrupar dados em 3 grupos.
- Um algoritmo de **clusterização** seria capaz de **analisar os dados** e **identificar esses grupos** baseado nas **características** desses dados.

Aprendizagem Não-supervisionada

Clusterização

- É uma técnica muito **poderosa** e tem uma **aplicabilidade** muito alta.

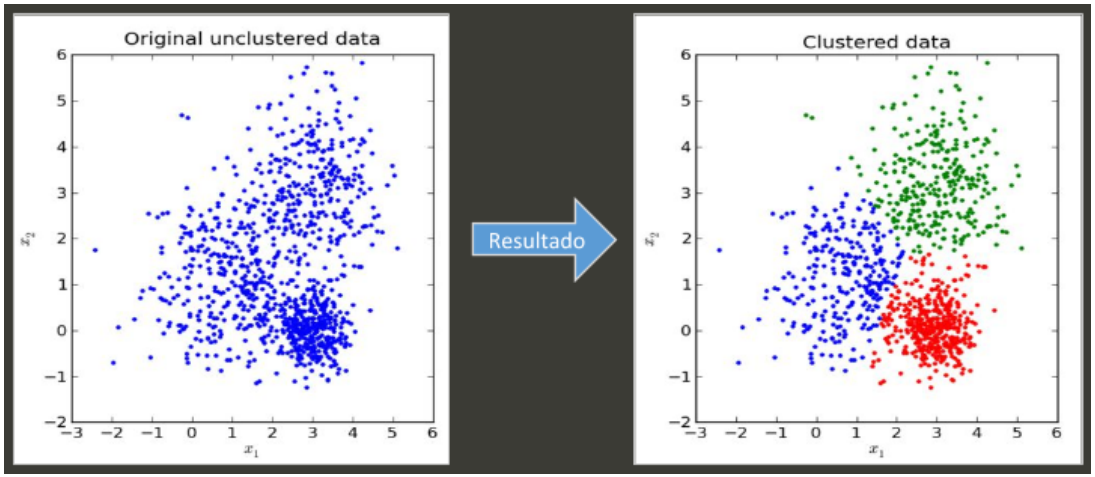

Aprendizagem Não-supervisionada

Clusterização - Exemplos

- Identificação de **clientes similares** e com isso ser mais assertivo ao oferecer um novo produto;
- Agrupamento de **pacientes** com os **mesmos sintomas**;
- Classificação de documentos;
- **Qualquer agrupamento** de uma grande quantidade de dados baseado em suas **características**.

Sumário

Base de Dados: Iris Dataset

Iris Dataset

- Problema proposto: através das características fornecidas de uma flor, descobrir de qual dos 3 tipos de flores se trata.
- 150 entradas.
- 4 features.

Iris Setosa

Iris Virginica

Iris Versicolor

Base de Dados: Iris Dataset

Iris Dataset

- Features: Comprimento da Sépala, Largura da Sépala, Comprimento da Pétala, Largura da Pétala.

	SepalLength	SepalWidth	PetalLength	PetalWidth	Species
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

Algoritmo de Classificação: SVM

SVM

- Algoritmo de classificação **supervisionado** que tenta criar uma **linha** (ou fronteira) que melhor separa os dados.
- Tipicamente, chamamos esta "linha" de **"hiperplano"**.
- O **melhor hiperplano** é que resulta em **maior distância marginal**.

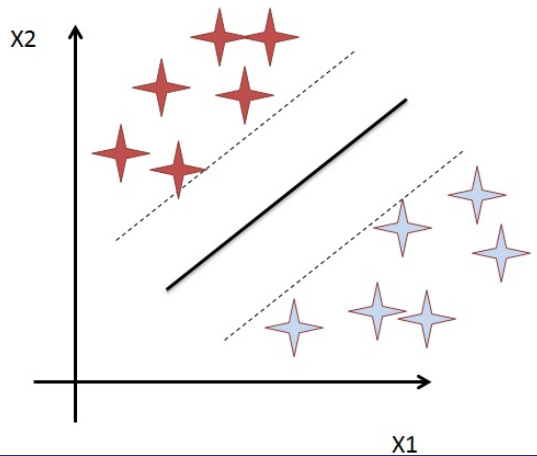

Algoritmo de Classificação: SVM

SVM

- **Vetores de suporte** são calculados para então escolher o melhor hiperplano.
- **Vetores de suporte** são **pontos** que estão **mais próximos** das linhas. A distância entre esses pontos é chamada de **margem**.
- O algoritmo escolhe um **hiperplano** que tem uma **margem maior**.

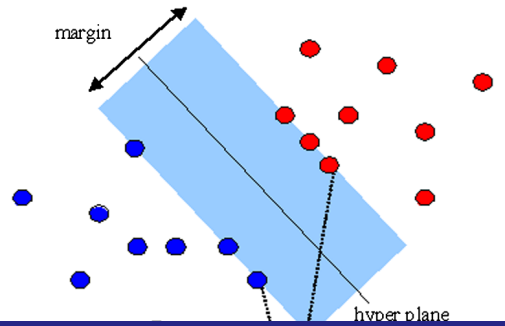

Algoritmo de Classificação: SVM

SVM

- Ao receber uma **amostra desconhecida**, verifica-se que **lado da margem** ela está e sua **distância**.
- Desta forma, é possível determinar **sua classe**.

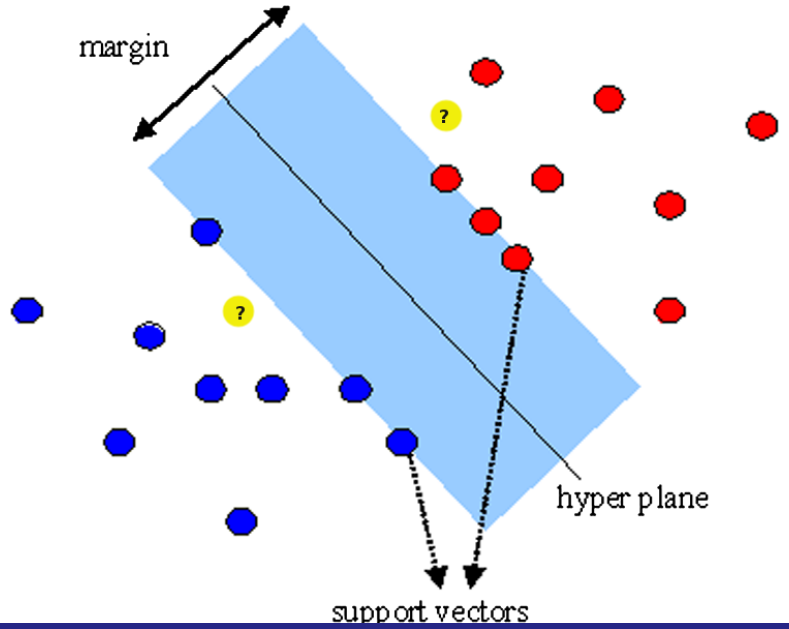

Execução do Algoritmo SVM

```
from sklearn import datasets
```

Execução do Algoritmo SVM

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

Execução do Algoritmo SVM

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
print(iris.data)
```

Execução do Algoritmo SVM

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
print(iris.data)
```

```
print(iris.target)
```

Execução do Algoritmo SVM

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
print(iris.data)
```

```
print(iris.target)
```

```
print(iris.data.shape)
```

Execução do Algoritmo SVM

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
print(iris.data)
```

```
print(iris.target)
```

```
print(iris.data.shape)
```

```
print(iris.target.shape)
```

Execução do Algoritmo SVM

```
from sklearn.model_selection import train_test_split
```

Execução do Algoritmo SVM

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split (iris.data,
iris.target, test_size=0.4, random_state=0)
```

Execução do Algoritmo SVM

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split (iris.data,
iris.target, test_size=0.4, random_state=0)
```

```
from sklearn import svm
```

Execução do Algoritmo SVM

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split (iris.data,
iris.target, test_size=0.4, random_state=0)
```

```
from sklearn import svm
```

```
clf = svm.SVC(kernel= 'linear', C=1).fit(X_train, y_train)
```

Execução do Algoritmo SVM

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split (iris.data,
iris.target, test_size=0.4, random_state=0)
```

```
from sklearn import svm
```

```
clf = svm.SVC(kernel= 'linear', C=1).fit(X_train, y_train)
```

```
print(clf.score(X_test, y_test))
```

Algoritmo de Classificação: SVM

Parâmetro C do SVM

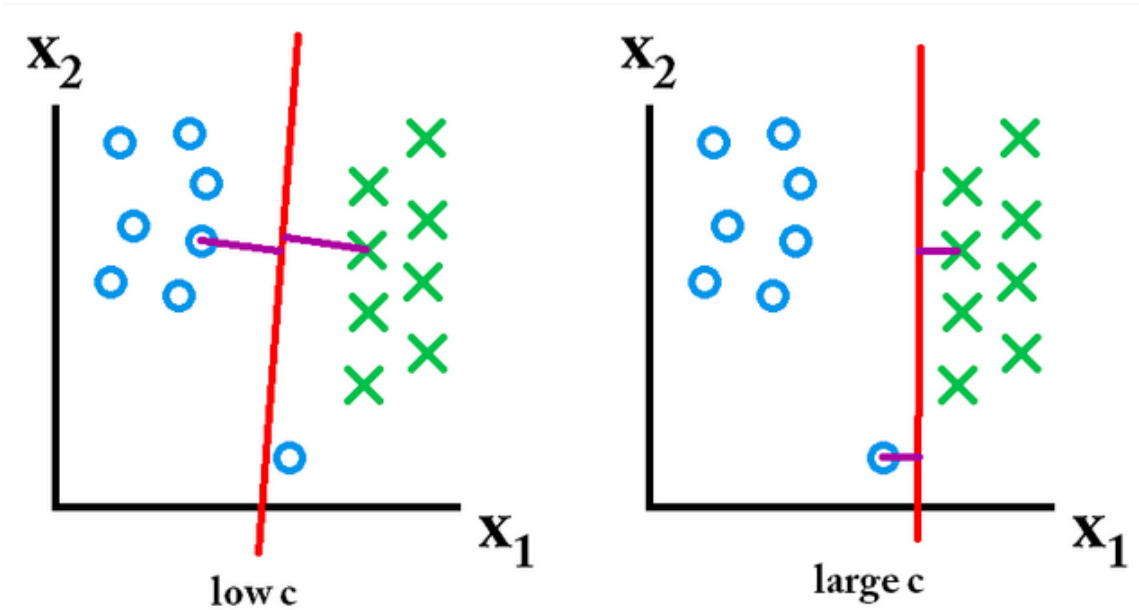

Algoritmo de Clusterização: K-Means

K-means

- O K-means é um algoritmo do tipo **não-supervisionado**, ou seja, que não trabalha com dados rotulados.
- Seu objetivo é encontrar **similaridades** entre os dados e **agrupá-los** conforme o **nº de clusters** passado pelo argumento **k**.
- Seu processo é composto por **4 etapas**.

Algoritmo de Clusterização: K-Means

1 - Inicialização

- O algoritmo gera de forma **aleatória** K centróides dentre dados (pontos) existentes.
- **Centróides** são os **pontos centrais dos clusters**.

Algoritmo de Clusterização: K-Means

2 - Atribuição ao cluster

- É computada a **distância** entre cada **ponto** e cada centróide.
- Cada **ponto** é **atribuído** ao **cluster** cuja distância ao seu centróide seja a **menor**.
- Cálculo de distância: Euclidiana.

Algoritmo de Clusterização: K-Means

3 - Movimentação de centróides

- **Recálculo** dos centróides.
- Faz-se a **média dos pontos de cada cluster** e o ponto médio será o novo centróide.

Algoritmo de Clusterização: K-Means

4 - Otimização

- As fases 2 e 3 são **repetidas** até o cluster se tornar **estático** ou **algum critério de parada** tenha sido atingido.
- Por fim, o K-means chega ao **fim da sua execução** dividindo os dados no **número de clusters especificado** pelo argumento k.

Execução do Algoritmo K-Means

```
from sklearn import datasets
```

Execução do Algoritmo K-Means

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

Execução do Algoritmo K-Means

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
X=iris.data
```

Execução do Algoritmo K-Means

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
X=iris.data
```

```
from sklearn.cluster import KMeans
```

Execução do Algoritmo K-Means

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
X=iris.data
```

```
from sklearn.cluster import KMeans
```

```
kmeans = KMeans(n_clusters = 3, init = 'random')
```

Execução do Algoritmo K-Means

```
from sklearn import datasets
```

```
iris= datasets.load_iris()
```

```
X=iris.data
```

```
from sklearn.cluster import KMeans
```

```
kmeans = KMeans(n_clusters = 3, init = 'random')
```

```
kmeans.fit(X)
```

Execução do Algoritmo K-Means

```
print(kmeans.cluster_centers_)
```

Execução do Algoritmo K-Means

```
print(kmeans.cluster_centers_)
```

```
distance = kmeans.fit_transform(X)
```

Execução do Algoritmo K-Means

```
print(kmeans.cluster_centers_)
```

```
distance = kmeans.fit_transform(X)
```

```
print(distance)
```

Execução do Algoritmo K-Means

```
print(kmeans.cluster_centers_)
```

```
distance = kmeans.fit_transform(X)
```

```
print(distance)
```

```
labels = kmeans.labels_
```

Execução do Algoritmo K-Means

```
print(kmeans.cluster_centers_)
```

```
distance = kmeans.fit_transform(X)
```

```
print(distance)
```

```
labels = kmeans.labels_
```

```
print(labels)
```

Execução do Algoritmo K-Means - Visualização de Dados

```
import matplotlib.pyplot as plt
plt.scatter(X[:, 0], X[:,1], s = 100, c = kmeans.labels_)
plt.scatter(kmeans.cluster_centers_[:, 0],
kmeans.cluster_centers_[:, 1], s = 300, c = 'red',label = 'Centroides')
plt.title('Clusteres e Centroides do Dataset Iris')
plt.xlabel('Comprimento da Sépala')
plt.ylabel('Largura da Sépala')
plt.legend()
plt.show())
```

Execução do Algoritmo K-Means - Visualização de Dados

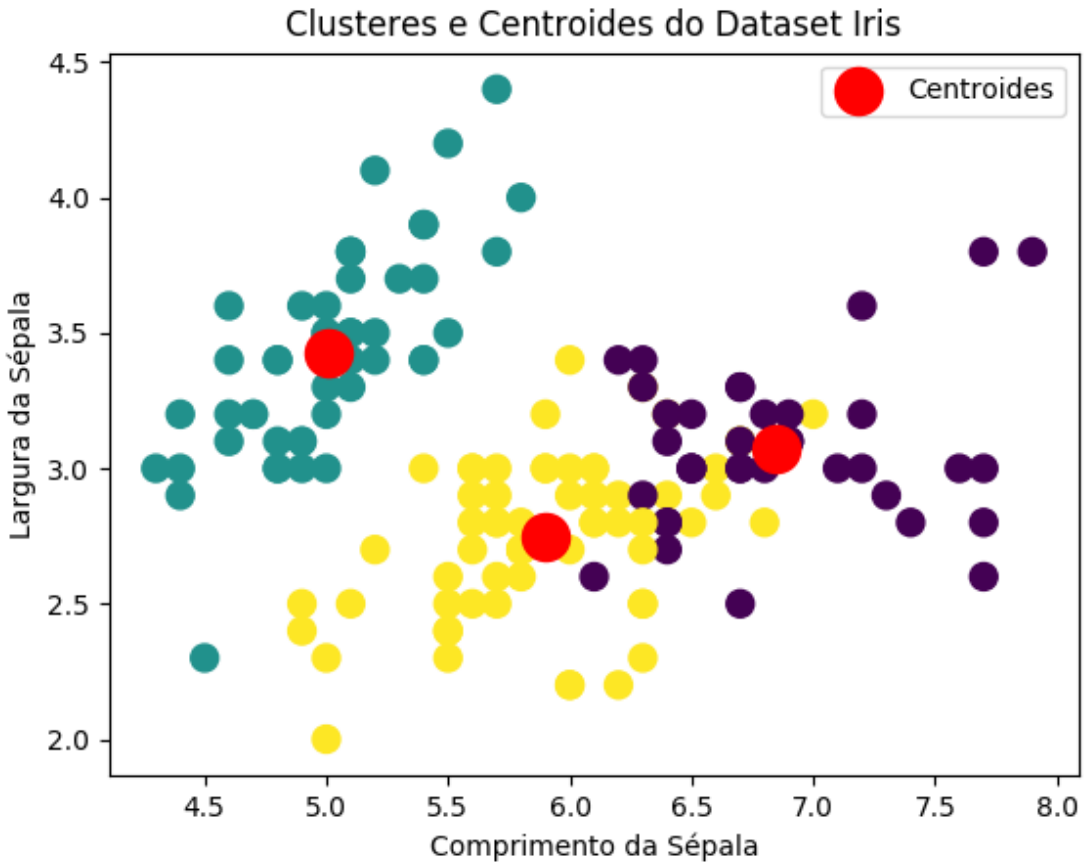

Sumário

Extra

- Existem diversas formas de se aplicar ML, **diferentes linguagens e bibliotecas**.
- Optamos por trabalhar a linguagem **Python** através do **Anaconda** e com a biblioteca **SciKit Learn**, que é uma poderosa biblioteca que possui **algoritmos de ML** implementados.
- Além disso, utilizamos a biblioteca **Matplotlib** para visualizar **gráficos 2D**.

Instalação do Anaconda no Ubuntu

No terminal do Ubuntu digite:[1]

- cd tmp
- sudo apt-get install curl
- curl -O https://repo.continuum.io/archive/Anaconda3-5.0.1-Linux-x86_64.sh
- sha256sum Anaconda3-5.0.1-Linux-x86_64.sh
- bash Anaconda3-5.0.1-Linux-x86_64.sh

```
Output

Welcome to Anaconda3 5.0.1 (by Continuum Analytics, Inc.)

In order to continue the installation process, please review the license
agreement.
Please, press ENTER to continue
```

Instalação do Anaconda no Ubuntu

No terminal do Ubuntu digite:[1]

- source ∼/.bashrc
- cd ∼/anaconda3/bin/
- ./conda create -name my_env python
- source activate my_env
- pip install -U scikit-learn
- pip install matplotlib
- python nomedoarquivo.py

[1] Referência: https://www.digitalocean.com/community/tutorials/how-to-install-the-anaconda-python-distribution-on-ubuntu-16-04

Perguntas

Agradecimentos

Agradecimentos

- A UEMG e a coordenação do FIDETEC pelo convite.
- A todos presentes!

Informações e Contatos

Contatos

- Slides e códigos disponibilizados no GitHub: https://github.com/samirasilva/MiniCursoMachineLearningUEMG2018
- E-mail: samirapgti@gmail.com

Mais informações

- Curso da Udacity: "Introdução ao Aprendizado de Máquina"
  - https://br.udacity.com/course/intro-to-machine-learning–ud120

Agradecimentos